
Détecter la langue de bois dans les professions de foi électorales françaises (1981–1993) : dictionnaire psycholinguistique et classification supervisée

Dikra Ben Belgacem
ENSAE Paris
MS Data Science
Professeur : Axel Morin

Avril 2026

Abstract

Comment mesurer le degré de *langue de bois* dans un discours politique ? Ce rapport présente une tentative de réponse appliquée au corpus Archelec (Sciences Po), qui rassemble plus de 12 000 professions de foi couvrant les élections françaises de 1981, 1988 et 1993. Le travail se décompose en deux volets. Le premier, que j'ai mené, consiste à construire un dictionnaire de marqueurs rhétoriques en combinant lecture manuelle de textes du corpus et enrichissement via la base psycholinguistique de Brysbaert et al. (2014), puis à le valider sur des candidats aux styles contrastés. Le second volet, développé par ma coéquipière Cindy Tran, met en place un pipeline de classification supervisée qui associe des features linguistiques interprétables à des embeddings CamemBERT pour prédire, phrase par phrase, la présence de langue de bois sur l'ensemble du corpus. Les résultats sont rendus explorables via deux dashboards Streamlit.

1 Introduction

Tout le monde a déjà eu cette impression, en écoutant un discours politique, que les mots sonnent creux, que le candidat parle sans rien dire de précis. C’est ce qu’on appelle couramment la *langue de bois* : un registre fait de grandes valeurs abstraites, de promesses vagues et de formules rituelles, qui contraste avec un discours ancré dans le concret, les chiffres et les engagements vérifiables.

Si le phénomène est bien connu et souvent commenté dans la presse ou la littérature politique [Delporte, 2009], il reste difficile à mesurer de façon systématique. Les professions de foi électorales offrent un terrain d’étude particulièrement adapté : ce sont des documents normés, distribués à chaque électeur, dans lesquels chaque candidat condense sa stratégie discursive en quelques pages.

Le corpus Archelec, constitué et numérisé par Sciences Po [Gaultier-Voituriez, 2017], met à disposition plus de 12 000 de ces professions de foi, couvrant les élections législatives et présidentielles de 1981 à 1993. C’est sur ce corpus que porte notre projet. Le travail a été réalisé en binôme avec Cindy Tran : j’ai pris en charge la construction et la validation du dictionnaire de langue de bois (sections 4 à 5), tandis que Cindy a développé le pipeline de traitement, la modélisation et les dashboards (section 6). Le code est commun et disponible sur GitHub¹.

2 Données

2.1 Le corpus Archelec

Les données sont extraites d’un export SQLite de la plateforme Arkindex, qui contient les professions de foi numérisées et transcrites par OCR. L’extraction des textes bruts depuis cette base a été réalisée par Cindy Tran (`pipeline/extract_text.py`). Le corpus comprend 12 876 documents répartis sur trois scrutins (voir tableau 1 en annexe) : 3 182 professions de foi pour les législatives de 1981, 3 628 pour celles de 1988, 130 discours présidentiels de 1988, et 5 936 professions de foi pour les législatives de 1993.

2.2 Pré-traitement et segmentation

Les textes bruts sont loin d’être propres : on y trouve des en-têtes administratifs (“Sciences Po / CEVIPOF”, mentions d’imprimerie), des lignes biographiques courtes (“44 ans, marié, deux enfants”), et pas mal d’artefacts OCR. Cindy a mis en place un filtre en cascade (`pipeline/sentences.py`) qui traite chaque ligne selon trois critères : d’abord des marqueurs explicites détectés par expressions régulières, puis des patterns biographiques, et enfin le rejet des lignes courtes sans verbe conjugué.

Un point intéressant de cette approche : la proportion de lignes filtrées par document (`filter_ratio`) est conservée comme feature tout au long du pipeline. L’idée est qu’un document dont 70% des lignes sont administratives n’a pas la même structure qu’un discours homogène, et cette information peut aider le modèle à mieux pondérer ses prédictions. La segmentation en phrases utilise NLTK [Bird et al., 2009], et les phrases de moins de quatre mots sont écartées. Au total, environ 110 000 phrases sont retenues.

3 État de l’art

La question de la langue de bois se situe au croisement de plusieurs problématiques en TAL : l’analyse de la *vagueness* dans le discours [Channell, 1994], la détection du sentiment politique [Liu, 2012], et plus largement l’analyse computationnelle du discours.

Approches lexicales et psycholinguistiques. L’utilisation de dictionnaires pour caractériser un style discursif est une approche classique. Le programme LIWC [Pennebaker et al., 2001] associe des catégories psychologiques à des listes de mots. Dans un registre voisin, Brysbaert et al. [Brysbaert et al., 2014] ont constitué une base de scores de concrétude pour environ 40 000 lemmes anglais : chaque mot reçoit une note de 1 (très abstrait : *freedom, justice*) à 5 (très concret : *table, knife*). L’hypothèse sous-jacente à notre travail est qu’un discours riche en langue de bois mobilise davantage de termes abstraits.

1. <https://github.com/cindyoff/ml-nlp>

Représentations contextuelles. Les modèles de langue pré-entraînés, notamment CamemBERT [Martin et al., 2020] pour le français, permettent d’encoder le sens contextuel d’une phrase en un vecteur dense de 768 dimensions. Par rapport à un simple comptage lexical, ces représentations capturent des nuances sémantiques et syntaxiques qui échappent à l’approche par dictionnaire.

Classification du discours politique. Plusieurs travaux ont abordé la classification automatique du discours politique en combinant features artisanales et embeddings [Card et al., 2015]. La difficulté principale, et qui se pose aussi dans notre cas, est l’absence de corpus annoté spécifiquement pour la langue de bois, ce qui oblige à constituer soi-même un jeu d’annotation.

4 Construction du dictionnaire

Cette partie constitue ma contribution principale au projet. L’objectif est de construire un dictionnaire de mots et expressions caractéristiques de la langue de bois politique, en s’appuyant sur deux sources complémentaires.

4.1 Lecture manuelle et catégorisation

J’ai lu attentivement huit professions de foi couvrant six formations politiques (LO, RPR, PS, PSU, FN, LCR) sur les trois scrutins du corpus (1981, 1988, 1993). Cette lecture m’a permis de dégager quatre grandes catégories de marqueurs.

La première catégorie regroupe les **valeurs abstraites**, c’est-à-dire des mots qui évoquent un idéal sans contenu précis : *avenir, solidarité, fraternité, dignité*. Ce sont des termes que personne ne contesterait, mais qui ne disent rien de concret. La deuxième catégorie concerne les **promesses vagues**, des verbes d’action sans engagement chiffré ni calendrier comme *défendre, renforcer, moderniser* ou *bâtir*. Le candidat promet d’agir mais ne précise jamais comment ni quand. Vient ensuite l’**auto-légitimation**, ces formules par lesquelles le candidat se met en valeur : *a fait ses preuves, compétence, expérience, vous pouvez compter sur moi*. Enfin, les **formules incantatoires** sont des expressions rituelles qui ponctuent ou concluent le discours : *ensemble, pour notre pays, vive la République*. Elles servent de marqueurs d’appartenance plus qu’elles ne transmettent un contenu.

Cette première passe produit un dictionnaire de 115 entrées.

4.2 Enrichissement via la base Brysbaert

Pour ne pas rester prisonnier des seules formulations rencontrées dans les huit textes lus, j’ai cherché à enrichir le dictionnaire à partir de la base psycholinguistique de Brysbaert et al. [Brysbaert et al., 2014]. L’idée est simple : si la langue de bois se caractérise par un recours à l’abstraction, alors les mots les plus abstraits de cette base (score de concrétude ≤ 2) sont de bons candidats.

Le problème, c’est que la base est en anglais. J’ai donc traduit les 2 000 premiers mots abstraits en français à l’aide du modèle de traduction Helsinki-NLP/opus-mt-en-fr [Tiedemann & Thottingal, 2020]. La traduction automatique produit beaucoup de bruit : des mots hors sujet, mal traduits, ou sans pertinence politique. J’ai donc filtré manuellement les résultats pour ne garder que les 109 termes effectivement pertinents dans un contexte de discours politique français.

4.3 Fusion et dictionnaire final

La fusion des deux sources (dictionnaire manuel et sélection Brysbaert), après déduplication, donne un dictionnaire final de 118 entrées, sauvegardé dans `dictionnaire/dictionnaire_final_clean.txt`. Ce dictionnaire sert à la fois au scoring direct des documents et comme lexique de “mots vagues” dans le pipeline de features linguistiques développé par Cindy.

4.4 Scoring

Le score de langue de bois d’un texte est le ratio entre le nombre de termes du dictionnaire détectés et le nombre total de mots. Pour ne pas rater les formes fléchies (*défendrons, garantissait*, etc.), j’utilise

la lemmatisation via spaCy (fr_core_news_sm) : le lemme *défendre* dans le dictionnaire matche toutes les conjugaisons dans le texte.

5 Validation du dictionnaire

Un dictionnaire, aussi soigneusement construit soit-il, ne vaut que par sa capacité à discriminer. J’ai donc mis en place un protocole de validation en deux temps.

5.1 Validation quantitative sur candidats contrastés

J’ai sélectionné quatre professions de foi dont je connaissais le profil discursif par lecture directe. La hiérarchie obtenue (voir tableau 2 en annexe) est conforme aux attentes : Guidoni (PS), dont le texte est très dense en formules institutionnelles, obtient le score le plus élevé (2.27%), suivi de Boyon (RPR, 1.07%). Laguiller (LO, 0.72%) et Bouchardeau (PSU, 0.46%), dont le discours est volontairement concret et critique, obtiennent des scores nettement plus faibles. Le dictionnaire discrimine bien.

5.2 Vérification manuelle en contexte

Sur recommandation du professeur de TD, j’ai ajouté une étape de vérification manuelle. Pour chaque candidat, j’ai affiché tous les mots détectés par le dictionnaire avec leur contexte (une fenêtre de 60 caractères autour du mot), afin d’identifier les faux positifs et les faux négatifs (voir figure 1 en annexe).

Faux positifs identifiés. Cinq mots ont été retirés du dictionnaire. Le mot *chance*, chez Laguiller, est utilisé au sens concret de “chances d’obtenir satisfaction”, pas comme une valeur abstraite. Le mot *crise*, dans “crise économique” ou “23 millions de chômeurs”, relève du constat factuel, pas de la rhétorique creuse. *Faillite* décrit une réalité concrète chez Laguiller (“faillites pour les petits commerçants”). *Sens* est le plus souvent employé comme connecteur logique (“dans ce sens”) ou en méta-discours (“mots dévoyés de leur sens”). Enfin, *équilibre* apparaît dans un contexte critique et factuel (“retour à l’équilibre économique”), pas dans un registre rhétorique.

Faux négatifs ajoutés. Cinq termes ont été ajoutés après relecture : *confiance*, *rassemblement*, *renouveau*, *ambition* et *responsabilité*.

5.3 Impact de l’ajustement

L’ajustement (voir tableau 3 en annexe) renforce la hiérarchie : Guidoni passe de 2.27% à 2.53%, tandis que Laguiller baisse de 0.72% à 0.57%. Ce qui est intéressant, c’est que Laguiller avait plus de mots détectés (15) que Guidoni (9) *avant* le nettoyage, alors que son score global était plus faible. Cela s’explique par la longueur du texte, mais aussi par le fait que des mots comme *crise* ou *combat* apparaissent dans un contexte concret et critique chez Laguiller, et non dans un registre rhétorique. C’est la leçon principale de cette vérification : un même mot peut relever de la langue de bois ou d’un discours factuel selon le contexte, et le matching lexical de surface ne suffit pas à faire cette distinction.

J’ai aussi remarqué que les passages de clôture des professions de foi concentrent les marqueurs de langue de bois, même chez des candidats dont le reste du texte est concret. C’est un pattern récurrent qu’il serait intéressant d’exploiter dans un travail futur.

6 Pipeline de classification supervisée

Cette partie du projet a été développée par Cindy Tran. J’en décris ici les grandes lignes pour donner une vue d’ensemble de l’approche.

6.1 Architecture du pipeline

Le pipeline transforme les textes bruts en prédictions phrase par phrase à travers six étapes séquentielles, orchestrées par `main.py`. La première étape (`sentences.py`) assure le nettoyage des textes, le filtrage administratif et le découpage en phrases avec NLTK. Vient ensuite l’encodage de chaque phrase par CamemBERT (`camembert-base`) via mean pooling, produisant un vecteur de 768 dimensions (`embedder.py`). En parallèle, 17 features linguistiques interprétables sont calculées (`features_engineering.py`), réparties en cinq catégories : concrétude (chiffres, dates, montants, pourcentages), mots vagues (issus de mon dictionnaire), verbes modaux, entités nommées (via spaCy), et sentiment (via DistilCamemBERT). Ces deux représentations sont fusionnées (`merger.py`) sur une clé primaire par phrase. Les annotations manuelles sont ensuite associées (`labeler.py`), et les classifieurs sont entraînés et évalués (`modelisation.py`).

Il est à noter que le dictionnaire que j’ai construit est directement utilisé à l’étape de features engineering comme lexique de mots vagues : les features `n_vague_words` et `vague_ratio` comptent, pour chaque phrase, le nombre de mots présents dans `dictionnaire_final_clean.txt`.

6.2 Annotation

Faute de corpus annoté existant pour la langue de bois, Cindy a constitué un échantillon stratifié d’environ 1 100 phrases à partir de documents complets, puis les a annotées par classification zero-shot avec le modèle multilingue mDeBERTa-v3 [He et al., 2021] selon trois labels : *langue_de_bois*, *non_langue_de_bois* et *autre*. Pour la modélisation, seules les deux premières classes sont conservées.

6.3 Modèles

Cindy a entraîné deux modèles sur un split stratifié 70/15/15 (train/validation/test).

La **régression logistique** n’utilise que les 17 features linguistiques. La sélection des variables passe par deux filtres successifs : d’abord l’Information Value ($IV \geq 0.02$), qui mesure le pouvoir discriminant univarié de chaque feature, puis le test de Wald ($p \leq 0.05$), qui ne retient que les coefficients statistiquement significatifs. Le seuil de classification est calibré en minimisant le risque de Bayes sur le jeu de validation.

Le modèle **XGBoost** exploite à la fois les features linguistiques et les embeddings CamemBERT (785 dimensions au total). Les hyperparamètres sont optimisés par RandomizedSearchCV (30 itérations, 3 folds de validation croisée stratifiée). Le seuil de décision est calibré de la même façon que pour la régression logistique.

Les deux modèles produisent, pour chaque phrase du corpus, une probabilité et un label prédit, ce qui donne lieu à quatre nouvelles colonnes dans le fichier final : `proba_lr`, `pred_lr`, `proba_xgb`, `pred_xgb`.

6.4 Dashboards

Cindy a aussi développé deux dashboards Streamlit pour explorer les résultats. Le premier (`dashboard.py`) affiche le texte de chaque profession de foi avec les phrases détectées comme langue de bois surlignées, l’intensité de la couleur étant proportionnelle à la probabilité prédite (voir figure 4 en annexe). Le second (`statistique_resume.py`) présente les métriques de performance des modèles, les features sélectionnées avec leur IV et p-value, et une analyse complète des résidus.

7 Résultats et discussion

7.1 Le dictionnaire discrimine bien les profils discursifs

Le résultat le plus net de la validation est que la hiérarchie des scores correspond à ce qu’on attend par connaissance du contexte politique. Les candidats PS et RPR, dont les professions de foi mobilisent un registre institutionnel, obtiennent des scores plus élevés que les candidats LO et PSU, dont le discours est délibérément concret et critique. Ce résultat tient après ajustement par vérification manuelle, ce qui renforce la confiance dans la qualité du dictionnaire.

La vérification manuelle a aussi mis en lumière un phénomène intéressant : certains mots du dictionnaire, comme *combat* ou *protéger*, ont des usages très différents selon le contexte politique. Chez Laguiller, *combat* renvoie à une lutte sociale concrète ; chez un candidat RPR, il relève davantage de la dramatisation rhétorique. Le matching lexical de surface ne peut pas capturer cette distinction, ce qui constitue une limite intrinsèque de l’approche par dictionnaire.

7.2 Performance des modèles de classification

Les résultats des deux modèles entraînés par Cindy sont résumés dans le tableau 4 en annexe. Le jeu annoté contient 738 phrases d’entraînement (638 langue de bois, 100 non langue de bois), 159 de validation et 159 de test. Les figures 2 et 3 en annexe visualisent ces métriques par split.

La régression logistique est étonnamment parcimonieuse. Sur les 17 features linguistiques de départ, 11 passent le filtre par Information Value ($IV \geq 0.02$). Mais après le test de Wald, seules **trois** features survivent : `n_digits` (nombre de chiffres dans la phrase, $IV = 0.34$, $p = 0.002$), `sentiment_positive` ($IV = 0.11$, $p = 0.022$) et `sentiment_negative` ($IV = 0.09$, $p = 0.009$). Autrement dit, la présence de chiffres et la tonalité émotionnelle de la phrase suffisent à expliquer l’essentiel de la distinction entre langue de bois et discours concret, du moins dans le cadre de ce modèle linéaire. C’est un résultat qui rejoint l’intuition : un discours factuel contient des données chiffrées, tandis que la langue de bois s’en tient à l’émotion et à l’abstraction.

Il est à noter que le `vague_ratio` (issu de mon dictionnaire) passe le filtre IV (0.067) mais est éliminé par le test de Wald ($p = 0.085$). Cela ne signifie pas que le dictionnaire est inutile, il contribue au modèle univarié, mais son apport est absorbé par les autres features dans le modèle multivarié.

XGBoost surpasse la régression logistique, mais overfitte. Avec une AUC de 1.0 sur le train et 0.85 sur le test, le modèle XGBoost montre un overfitting clair. Cela dit, ses performances en test restent supérieures à celles de la régression logistique (AUC 0.85 vs 0.76, accuracy 90% vs 86%). L’ajout des embeddings CamemBERT (768 dimensions) permet donc de capturer des patterns sémantiques que les seules features linguistiques ne voient pas. Les hyperparamètres retenus par la recherche aléatoire (300 arbres, profondeur 3, learning rate 0.1, régularisation $\lambda = 5.0$) indiquent que le modèle a cherché un compromis entre expressivité et régularisation, même si l’overfitting n’a pas été totalement maîtrisé.

Le déséquilibre des classes pèse lourd. Le jeu annoté est fortement déséquilibré : 86% des phrases sont étiquetées comme langue de bois. Ce déséquilibre se reflète dans les résultats : les deux modèles atteignent un rappel élevé sur la classe majoritaire (94 à 99%), mais un rappel faible sur la classe minoritaire (29% pour les deux modèles en test). Concrètement, cela signifie que les modèles sont bons pour reconnaître la langue de bois, mais peinent à identifier les phrases concrètes quand elles sont rares dans le corpus annoté. Ce biais provient probablement de l’annotation zero-shot, qui a tendance à sur-étiqueter les phrases comme langue de bois.

7.3 Complémentarité dictionnaire et classification

L’intérêt du pipeline développé par Cindy est de dépasser les limites de l’approche par dictionnaire. En intégrant des embeddings CamemBERT, le modèle XGBoost peut en principe distinguer les usages rhétoriques des usages concrets d’un même mot, puisque le contexte de la phrase est encodé dans le vecteur. La régression logistique, de son côté, reste interprétable : le fait que `n_digits` soit la feature la plus discriminante ($IV = 0.34$) confirme que la concrétude, mesurée ici par la présence de données chiffrées, est un signal fort pour distinguer un discours factuel d’un discours creux.

7.4 Exploration qualitative et analyse des résidus

Le dashboard document développé par Cindy (figure 4 en annexe) permet de vérifier qualitativement la cohérence des prédictions. Les phrases surlignées avec une forte probabilité correspondent typiquement à des formulations attendues : “ensemble, défendons les valeurs de la République”, “au service de l’intérêt général”. Les phrases non surlignées contiennent plus souvent des chiffres, des noms propres et des engagements datés. Le seuil de surlignage est ajustable, ce qui permet d’explorer la zone d’incertitude du modèle.

Le dashboard statistique fournit une évaluation plus formelle via le test de Hosmer-Lemeshow. Pour la régression logistique (figure 5 en annexe), le test rejette l’hypothèse de bonne calibration ($\chi^2 = 81.9$, $p < 0.001$), ce qui indique que les probabilités prédites ne reflètent pas fidèlement les fréquences observées. Pour XGBoost (figure 6 en annexe), la calibration est acceptable ($\chi^2 = 11.4$, $p = 0.18$) : on ne rejette pas l’hypothèse nulle, le modèle est donc mieux calibré. La distribution des probabilités par classe réelle (figures 7 et 8 en annexe) confirme que XGBoost sépare mieux les deux classes, avec les phrases langue de bois concentrées au-delà de 0.8, tandis que pour la régression logistique les deux classes se chevauchent dans la zone 0.4 à 0.6.

7.5 Limites

Plusieurs limites méritent d’être signalées.

L’annotation par classification zero-shot, bien que pragmatique en l’absence de données annotées, introduit un biais. Le ratio 86/14 entre les deux classes suggère que le modèle d’annotation (mDeBERTa) a une conception assez large de ce qui constitue de la langue de bois. Une annotation humaine experte produirait probablement un jeu plus équilibré, et potentiellement de meilleurs résultats sur la classe minoritaire.

Le dictionnaire reste sensible à la polysémie. La vérification manuelle a permis de corriger les cas les plus flagrants, mais il est probable que d’autres faux positifs subsistent à l’échelle du corpus complet.

Le corpus OCRisé contient des erreurs de transcription qui affectent marginalement la détection : certains mots mal transcrits ne sont pas reconnus par le dictionnaire ni par le modèle de langue.

Enfin, le scoring par dictionnaire ne capture que la langue de bois *lexicale*, celle qui passe par un vocabulaire spécifique. Il existe aussi une langue de bois *structurelle*, qui repose sur la construction argumentative (enchaîner des énoncés sans lien logique, poser une question pour ne pas y répondre), et que notre approche ne détecte pas.

8 Conclusion

Ce projet propose une approche à deux niveaux pour détecter la langue de bois dans les professions de foi électorales françaises. Le dictionnaire psycholinguistique, construit manuellement puis enrichi par la base de Brysbaert, offre un outil interprétable et validé empiriquement. Le pipeline de classification, en combinant features linguistiques et embeddings contextuels, permet de passer à l’échelle sur l’ensemble du corpus.

La vérification manuelle des faux positifs et faux négatifs a constitué, à mes yeux, l’étape la plus instructive : elle a montré que la distinction entre usage rhétorique et usage concret d’un même mot est au cœur du problème, et qu’aucune approche purement lexicale ne peut la résoudre complètement. C’est précisément là que les embeddings contextuels apportent une valeur ajoutée.

Parmi les pistes d’amélioration, on pourrait envisager d’élargir l’échantillon annoté manuellement (par des annotateurs humains cette fois), d’intégrer des features positionnelles (la langue de bois se concentre-t-elle en début ou en fin de document ?), ou encore de tester la généralisabilité de l’approche sur des corpus plus récents, où les stratégies rhétoriques ont certainement évolué.

Remerciements

Je tiens à remercier ma coéquipière Cindy Tran pour son travail sur le pipeline de classification et les dashboards, sans lequel ce projet n’aurait pas la même envergure. Je remercie également Alexandre Doré, notre encadrant de TD, pour ses conseils précieux tout au long du projet, notamment sur la vérification manuelle du dictionnaire. Enfin, merci à Axel Morin pour ses séances de cours qui ont nourri notre réflexion sur les méthodes de TAL appliquées au discours politique.

Références

Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O’Reilly Media.

- Brysbaert, M., Warriner, A.B., & Kuperman, V. (2014). Concreteness ratings for 40 thousand generally known English word lemmas. *Behavior Research Methods*, 46 :904–911.
- Card, D., Gross, J., & Smith, N.A. (2015). The media frames corpus : Annotations of frames across issues. *Proceedings of ACL*, pp. 438–444.
- Channell, J. (1994). *Vague Language*. Oxford University Press.
- Delporte, C. (2009). *Une histoire de la langue de bois*. Flammarion.
- Gaultier-Voituriez, O. (2017). Archelec, les archives électorales françaises de la Ve République, du papier au numérique : reflet fidèle ou distorsion ? *Archives de Sciences Po*.
- He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa : Decoding-enhanced BERT with disentangled attention. *Proceedings of ICLR*.
- Liu, B. (2012). *Sentiment Analysis and Opinion Mining*. Morgan & Claypool.
- Martin, L., Muller, B., Suárez, P.J.O., Dupont, Y., Romary, L., de la Clergerie, É., Seddah, D., & Sagot, B. (2020). CamemBERT : A tasty French language model. *Proceedings of ACL*, pp. 7203–7219.
- Pennebaker, J.W., Francis, M.E., & Booth, R.J. (2001). *Linguistic Inquiry and Word Count : LIWC 2001*. Lawrence Erlbaum.
- Tiedemann, J. & Thottingal, S. (2020). OPUS-MT – Building open translation services for the world. *Proceedings of EAMT*.

A Tableaux

TABLE 1 – Composition du corpus Archelec.

Année / Type	Documents	Type
1981 / législatives	3 182	Professions de foi
1988 / législatives	3 628	Professions de foi
1988 / présidentielle	130	Discours présidentiels
1993 / législatives	5 936	Professions de foi
Total	12 876	

TABLE 2 – Scores de langue de bois avant ajustement.

Candidat	Parti	Score	Profil attendu
Guidoni (1988)	PS	2.27%	élevé
Boyon (1988)	RPR	1.07%	élevé
Laguiller (1981)	LO	0.72%	faible
Bouchardeau (1981)	PSU	0.46%	faible

TABLE 3 – Scores avant et après ajustement du dictionnaire.

Candidat	Parti	Avant	Après
Guidoni (1988)	PS	2.27%	2.53% (+0.26)
Boyon (1988)	RPR	1.07%	1.07% (+0.00)
Laguiller (1981)	LO	0.72%	0.57% (−0.15)
Bouchardeau (1981)	PSU	0.46%	0.46% (+0.00)

TABLE 4 – Performances des modèles sur les trois splits. Le F1 et le rappel sont reportés pour la classe *langue_de_bois* (classe majoritaire).

Modèle	Split	AUC-ROC	F1 (LdB)	Rappel (LdB)	Accuracy
Rég. logistique	Train	0.642	0.922	0.959	0.859
	Val	0.765	0.947	0.978	0.906
	Test	0.764	0.919	0.942	0.855
XGBoost	Train	1.000	1.000	1.000	1.000
	Val	0.879	0.944	0.986	0.899
	Test	0.852	0.945	0.993	0.899

B Figures

```
Faux positifs identifiés : 5
❌ "chance" → sens concret chez Laguiller ('chances d'obtenir satisfaction'), polysémique
❌ "crise" → constat factuel ('crise économique', '23 millions de chômeurs'), pas rhétorique creuse
❌ "faillite" → description concrète de la réalité économique chez Laguiller
❌ "sens" → usages variés (méta-discours, connecteur logique), rarement langue de bois
❌ "équilibre" → contexte critique/factuel chez Laguiller ('retour à l'équilibre')
```

FIGURE 1 – Faux positifs identifiés lors de la vérification manuelle, avec la justification en contexte pour chaque mot retiré.




FIGURE 2 – Performances de la régression logistique par split (dashboard développé par Cindy Tran). Les métriques sont stables entre validation et test.

Performances

Régression Logistique **XGBoost**

Split	AUC-ROC	Seuil	F1 (LDB)	Précision	Rappel	Accuracy
Train	1.000000	0.237000	1.000000	1.000000	1.000000	1.000000
Val	0.879200	0.237000	0.944400	0.906700	0.985500	0.899400
Test	0.851600	0.237000	0.944800	0.901300	0.992800	0.899400




FIGURE 3 – Performances de XGBoost par split. L' AUC parfaite sur le train (1.0) traduit un overfitting net, mais les performances en test restent supérieures à celles de la régression logistique.

Paramètres

Modèle
☒ Régression logistique
☐ XGBoost

Année
Toutes

Type d'élection
Tous

Seuil d'affichage (probabilité min.)
0.50

4185 document(s) disponibles

Stats corpus filtré

Phrases totales
109,957

Langue de bois (prédit)
98,004 (89.1%)

Documents
4185

Langue de bois — Visualisation

Premier
Précédent
EL134_L_1981_06_001_01_1_PF_03
Suivant

Document
Année
Type
Phrases

EL134_L_1981_0...
1981
legislatives
22

15 / 22 phrases langue de bois (68.2%) — modèle : Régression logistique

faible → forte intensité = probabilité prédite

Sciences Po / fonds CEVIPOF RÉPUBLIQUE FRANÇAISE - LIBERTÉ - ÉGALITÉ - FRATERNITÉ - DÉPARTEMENT DE L'AIN O PARTI SOCIALISTE MOUVEMENT DES RADICAUX DE GAUCHE Louis ROBIN candidat Dr Louis JANNEL remplaçant éventuel MADAME, MADemoiselle, MONSIEUR, La France vient de choisir un nouveau Président, François MITTERRAND engagera une nouvelle politique décidée par la majorité des Français. La circonscription doit porter à l'Assemblée Nationale un parlementaire qui appréciera cette politique mais qui aura également la charge de s'exprimer en votre nom. **La candidat, Louis ROBIN** Sciences Po / fonds CEVIPOF MADAME, MADemoiselle, MONSIEUR, Ma seule ambition, en m'engageant dans cette campagne aux côtés de Louis ROBIN, est de l'aider à être élu. Pour des raisons politiques : les Français ont choisi le changement ; une grande espérance est née ; pour qu'elle se concrétise, le Président de la République appelle au rassemblement ; il a besoin d'une large majorité. Le M.R.G., fidèle allié du P.S., doit donc jouer pleinement son rôle. Il sera le garant du développement des libertés, de la responsabilité individuelle, de l'esprit d'initiative, l'adversaire résolu de la bureaucratie, de la technologie, de la centralisation étatique. Pour des raisons locales : il est nécessaire que la Bresse soit représentée au Parlement par un des siens, un homme d'expérience, de terrain, apte à nous comprendre et à nous aider, qui sera d'autant plus efficace qu'il fera partie de la majorité présidentielle. Parce que Louis ROBIN est mon ami, je voudrais faire partager l'estime, la confiance, l'amitié, que j'éprouve à son égard. Le remplaçant éventuel, Louis JANNEL POUR REDRESSER LE PAYS - par une relance de l'activité économique ; en luttant efficacement contre le chômage ; en défendant le pouvoir d'achat des agriculteurs ; - en aidant les P.M.E. et les artisans qui constituent le tissu économique de notre pays. POUR LA PAIX SOCIALE, DANS LA JUSTICE ET LA FRATERNITÉ - pour aider les personnes âgées et les familles ; - pour que chacun puisse recevoir un salaire décent ; - pour que la société fasse aux jeunes la place nécessaire. POUR DÉFENDRE L'AIN - parce que notre circonscription doit être représentée par un député de la majorité présidentielle ; - parce que nos communes et nos cantons ont besoin d'hommes disponibles, dévoués et compétents, qui sachent les écouter et faire remonter à Paris votre message. Pour cette tâche j'ai l'honneur de solliciter vos suffrages pour l'action utile et efficace que vous attendez de votre député. Pour cela, dès le 1er tour, le 14 Juin, vous porterez vos suffrages sur des hommes de chez vous, attachés aux libertés, VOTEZ Louis ROBIN, Louis JANNEL IMP. DU CENTRE - BOURG L'Espoir est dans nos cœurs et nous devons entraîner avec nous toutes celles et ceux qui veulent dans la sécurité, le nécessaire changement. Si vous me désignez, votre nouveau député saura, grâce à l'amitié qui depuis 18 ans l'a rapproché de François MITTERRAND, faire passer votre message. Vous avez pu voir que dès maintenant le nouveau Gouvernement a pris des mesures importantes dans le sens d'une meilleure justice sociale, d'une plus grande fraternité telles que : - le relèvement de l'allocation vieillesse ; - le relèvement des allocations familiales ; - le relèvement de

FIGURE 4 – Dashboard de visualisation par document (développé par Cindy Tran). Les phrases détectées comme langue de bois sont surlignées du jaune (probabilité faible) au rouge (probabilité forte). Ici, document EL134, législatives 1981, modèle régression logistique, 15 phrases sur 22 détectées (68%).

Test de Hosmer-Lemeshow

χ^2

81.874

p-value

0.0000

⚠ Calibration douteuse ($p \leq 0.05$)

H_0 : le modèle est bien calibré. $p > 0.05 \rightarrow$ on ne rejette pas H_0 .

FIGURE 5 – Test de Hosmer-Lemeshow, régression logistique (jeu de test). La calibration est rejetée ($\chi^2 = 81.9$, $p < 0.001$).

Test de Hosmer-Lemeshow

χ^2

11.397

p-value

0.1802

✓ Bien calibré ($p > 0.05$)

H_0 : le modèle est bien calibré. $p > 0.05 \rightarrow$ on ne rejette pas H_0 .

FIGURE 6 – Test de Hosmer-Lemeshow, XGBoost (jeu de test). La calibration est acceptable ($\chi^2 = 11.4$, $p = 0.18$).




FIGURE 7 – Distribution des probabilités prédites par classe réelle, régression logistique. Les deux classes se chevauchent dans la zone 0.4 à 0.6.



FIGURE 8 – Distribution des probabilités prédites par classe réelle, XGBoost. Meilleure séparation : les phrases langue de bois sont concentrées vers les probabilités élevées (> 0.8).

C Détail du dictionnaire

Le dictionnaire final contient 118 entrées réparties en six catégories : valeurs abstraites (31 entrées), promesses vagues (23), auto-légitimation (21), dramatisation (16), fausse rupture (8), et formules incantatoires (16). Trois entrées supplémentaires proviennent de l'enrichissement Brysbaert sans appartenir à ces catégories. Après vérification manuelle, cinq entrées ont été retirées (*chance*, *crise*, *faillite*, *sens*, *équilibre*) et cinq ajoutées (*confiance*, *rassemblement*, *renouveau*, *ambition*, *responsabilité*).

Le dictionnaire complet est disponible dans le dépôt GitHub à l'adresse `dictionnaire/dictionnaire_final_clean.txt`.